你真正能发出去的后端是哪一个?

端侧 ASR 运行时：4 个后端 × 3 个目标平台。颜色越深越接近可发布。2026-11

越难发版 → 今天就能发版　　= 该格不存在（附官方依据，见注脚）

硬约束「CPU 能跑 · 流式 · 可分发」： 12 格里只有 2 格通过。

GGUF 卡流式 · TensorRT 卡 CPU · ncnn 那格尚未实测

	x86-64 CPU	x86-64 + NVIDIA GPU	Windows arm64
sherpa-onnx ONNX Runtime	**首选** 今天就能发 · 96 MB Lite 流式 + 5 种语言 + 标点	**可用** ONNX Runtime 有 CUDA EP 本产品未启用 · 未实测	**可用** 有 win_arm64 轮子 无硬件可测
sherpa-ncnn ncnn	**可用 · 运行时未测** 官方已发 SenseVoice ncnn 包 ⑤ 本机从未装 · 无 RTF 数据	**可用** 走 Vulkan / GPU 路径 静态链接、无额外依赖	**无轮子** sherpa-ncnn 2.1.15 只发 win32 / win_amd64 ③
GGUF (llama.cpp) ggml	**可用，但非流式** SenseVoiceSmall-GGUF 8 线程 8.01% CER ④	**可用** llama.cpp 有 CUDA 后端 单文件、零依赖	**未验证** llama.cpp 本身能编 arm64 预编译产物未见确认
TensorRT NVIDIA SDK	**不存在** NVIDIA：无 CPU 支持， 只能在 GPU 上运行 ①	**可用，一机一引擎** engine 绑定构建它的设备 11.3 起不再支持 JetPack ②	**不存在** 没有 Windows arm64 target Jetson 走 Linux ①②

① TensorRT 的 CPU 列不是「慢」，是「不存在」。NVIDIA 自家的 Triton 后端支持矩阵里，x86 与 ARM-SBSA 都只有 GPU，没有 CPU。

② TensorRT engine 默认只与构建它的设备兼容；hardware compatibility 仅支持 Ampere 及以后，且 JetPack / Jetson 不支持。11.3 不再支持 JetPack。

③ 实测 PyPI JSON：sherpa-ncnn 2.1.15 只有 cp313 win32 / win_amd64 轮子，无 win_arm64；sherpa-onnx 2.0.1 有 win_arm64。

④ 现有 GGUF ASR 基本是非流式（SenseVoiceSmall-GGUF = SAN-M encoder + CTC，整段输入）。它的强项是离线批量与单文件零依赖，不是实时字幕。

⑤ sherpa-ncnn 官方已发 SenseVoice 的 ncnn 预编译模型包（release tag asr-models，2025-09-13，含 int8 / float32）。缺的不是模型，是实测。

⑥ 本机只在 Android 真机上跑过 ncnn（2026-10-25 改造 APK 装机），Windows x86-64 未装 sherpa_ncnn；Android 不在本图平台列内。