Which backend can you actually ship?

端侧 ASR 运行时可用性：4 个运行时 × 3 个目标平台。颜色越深越可用。

less usable → ship today　= 该格不存在（附官方依据，见注脚）

12 个格子里，只有 1 格同时满足「CPU 能跑 + 流式 + 能给未知用户分发」。

	x86-64 CPU	x86-64 + NVIDIA GPU	Windows arm64
sherpa-onnx ONNX Runtime	**best** ships today · 96 MB Lite streaming + 5 languages	**ok** CUDA EP exists not enabled / untested here	**ok** win_arm64 wheel exists no hardware to test
sherpa-ncnn ncnn	**limited** no stronger model to switch to ⑤ needs pnnx re-export	**ok** Vulkan / GPU path static link, no extra deps	**no wheel** sherpa-ncnn 2.1.15 ships win32 / win_amd64 only ③
GGUF (llama.cpp) ggml	**ok, but non-streaming** SenseVoiceSmall-GGUF 8.01% CER @ 8 threads ④	**ok** llama.cpp CUDA backend single binary, zero deps	**unverified** llama.cpp builds, but no confirmed prebuilt arm64
TensorRT NVIDIA SDK	**does not exist** NVIDIA: "Does TensorRT run on a CPU? No." ①	**ok, per-device engine** engine bound to build device JetPack unsupported by 11.3 ②	**does not exist** no Windows arm64 target; Jetson is Linux-only ①②

① TensorRT 的 CPU 列不是「慢」，是「不存在」。NVIDIA 官方 FAQ 原文：Does TensorRT run on a CPU? No. TensorRT needs an NVIDIA GPU or Jetson module.

② TensorRT engine 默认只与构建它的设备兼容；hardware compatibility 仅支持 Ampere 及以后，且 JetPack / Jetson 不支持。11.3 不再支持 JetPack。

③ 实测 PyPI JSON：sherpa-ncnn 2.1.15 只有 cp313 win32 / win_amd64 轮子，无 win_arm64；sherpa-onnx 2.0.1 有 win_arm64。

④ 现有 GGUF ASR 基本是非流式（SenseVoiceSmall-GGUF = SAN-M encoder + CTC，整段输入）。它的强项是离线批量与单文件零依赖，不是实时字幕。

⑤ ncnn 侧最强中英双语模型被实证是官方 bilingual-2023-02-13 的换皮：param / tokens 的 md5 完全一致，纯改名未微调。

数据源：本仓库实测 + 官方文档；空格子给依据，不给猜测